

Авторские права

© Postgres Professional, 2015–2022 Авторы: Егор Рогов, Павел Лузанов, Илья Баштанов

Использование материалов курса

Некоммерческое использование материалов курса (презентации, демонстрации) разрешается без ограничений. Коммерческое использование возможно только с письменного разрешения компании Postgres Professional. Запрещается внесение изменений в материалы курса.

Обратная связь

Отзывы, замечания и предложения направляйте по адресу: edu@postgrespro.ru

Отказ от ответственности

Компания Postgres Professional не несет никакой ответственности за любые повреждения и убытки, включая потерю дохода, нанесенные прямым или непрямым, специальным или случайным использованием материалов курса. Компания Postgres Professional не предоставляет каких-либо гарантий на материалы курса. Материалы курса предоставляются на основе принципа «как есть» и компания Postgres Professional не обязана предоставлять сопровождение, поддержку, обновления, расширения и изменения.

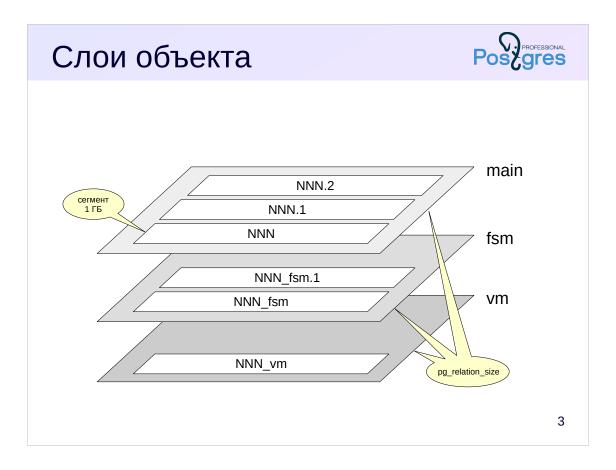
Темы



Файлы данных

Слои: данные, карты видимости и свободного пространства Длинные версии строк и TOAST

2



Обычно каждому объекту БД, хранящему данные (таблице, индексу, последовательности, материализованному представлению), соответствует несколько *слоев* (forks). Каждый слой содержит определенный вид данных.

Вначале слой содержит один-единственный файл. Имя файла состоит из числового идентификатора, к которому может быть добавлено окончание, соответствующее имени слоя.

Файл постепенно растет и, когда его размер доходит до 1 Гбайта, создается следующий файл этого же слоя. Такие файлы иногда называют сегментами. Порядковый номер сегмента добавляется в конец имени файла. Общий размер любого слоя показывает функция pg_relation_size.

Ограничение размера файла в 1 Гбайт возникло исторически для поддержки различных файловых систем, некоторые из которых не умеют работать с файлами большого размера. Установить другой размер можно только при сборке сервера из исходных кодов (--with-segsize).

Таким образом, одному объекту БД на диске может соответствовать несколько файлов. Для небольшой таблицы их будет 3, для индекса — два. Все файлы объектов, принадлежащих одному табличному пространству и одной БД, будут помещены в один каталог. Это необходимо учитывать, потому что файловые системы могут не очень хорошо работать с большим количеством файлов в каталоге.

Слои



Основной слой

собственно данные (версии строк) существует для всех объектов

Слой инициализации (init)

«пустышка» для основного слоя используется при сбое; только для нежурналируемых таблиц

Карта видимости (vm)

существует только для таблиц

Карта свободного пространства (fsm)

существует и для таблиц, и для индексов

4

Посмотрим теперь на типы слоев.

Основной слой — это собственно данные: версии строк таблиц или индексные записи. Имена файлов основного слоя совпадают с идентификатором. Основной слой существует для любых объектов.

Имена файлов слоя инициализации оканчиваются на «_init». Этот слой существует только для нежурналируемых таблиц (созданных с указанием UNLOGGED) и их индексов. Такие объекты ничем не отличаются от обычных, но действия с ними не записываются в журнал упреждающей записи. За счет этого работа с ними происходит быстрее, но в случае сбоя их содержимое невозможно восстановить. При восстановлении PostgreSQL просто удаляет все слои таких объектов и записывает слой инициализации на место основного слоя. В результате получается пустая таблица.

https://postgrespro.ru/docs/postgresql/13/storage-init

Слой vm (visibility map) — битовая карта видимости. Имена файлов этого слоя оканчиваются на «_vm». Слой существует только для таблиц; для индексов не поддерживается отдельная версионность.

Слой fsm (free space map) — *карта свободного пространства*. Имена файлов этого слоя оканчиваются на «_fsm». Этот слой существует и для таблиц, и для индексов.

Про две эти карты рассказывалось в модуле «Архитектура».

https://postgrespro.ru/docs/postgresql/13/storage-fsm

https://postgrespro.ru/docs/postgresql/13/storage-vm

Расположение файлов

```
=> CREATE DATABASE data_lowlevel;
CREATE DATABASE
=> \c data_lowlevel
You are now connected to database "data_lowlevel" as user "student".
Создадим таблицу и посмотрим на файлы, принадлежащие ей.
=> CREATE TABLE t(
 id integer PRIMARY KEY GENERATED ALWAYS AS IDENTITY,
 n numeric
CREATE TABLE
=> INSERT INTO t(n) SELECT id FROM generate_series(1,10000) AS id;
=> VACUUM t:
VACUUM
Путь до основного файла относительно PGDATA можно получить функцией:
=> SELECT pg_relation_filepath('t');
pg relation filepath
base/16527/16530
(1 row)
Поскольку таблица находится в табличном пространстве pg default, путь начинается с base. Затем идет имя
каталога для базы данных:
=> SELECT oid FROM pg database WHERE datname = 'data lowlevel';
 oid
16527
(1 row)
Затем — собственно имя файла. Его можно узнать следующим образом:
=> SELECT relfilenode FROM pg class WHERE relname = 't';
relfilenode
      16530
(1 row)
Тем и удобна функция pg relation filepath, что выдает готовый путь без необходимости выполнять несколько
запросов к системному каталогу.
Посмотрим на файлы. Доступ к каталогу PGDATA имеет только пользователь OC postgres, поэтому команда ls
выдается от его имени:
postgres$ ls -l /var/lib/postgresql/13/main/base/16527/16530*
-rw----- 1 postgres postgres 450560 мая 28 22:36 /var/lib/postgresql/13/main/base/16527/16530
-rw----- 1 postgres postgres 24576 mag 28 22:36 /var/lib/postgresql/13/main/base/16527/16530 fsm
-rw----- 1 postgres postgres 8192 mas 28 22:36 /var/lib/postgresql/13/main/base/16527/16530_vm
Мы видим три слоя: основной слой, карту свободного пространства (fsm) и карту видимости (vm).
Аналогично можно посмотреть и на файлы индекса:
=> \d t
```

```
Table "public.t"
Column | Type | Collation | Nullable |
                                                  Default
id | integer |
n | numeric |
                            | not null | generated always as identity
Indexes:
   "t_pkey" PRIMARY KEY, btree (id)
=> SELECT pg relation filepath('t_pkey');
pg_relation_filepath
base/16527/16536
(1 row)
postgres$ ls -l /var/lib/postgresql/13/main/base/16527/16536*
-rw----- 1 postgres postgres 245760 мая 28 22:36 /var/lib/postgresql/13/main/base/16527/16536
И на файлы последовательности, созданной для первичного ключа:
=> SELECT pg_relation_filepath(pg_get_serial_sequence('t','id'));
pg relation filepath
base/16527/16528
(1 row)
postgres$ ls -l /var/lib/postgresql/13/main/base/16527/16528*
-rw----- 1 postgres postgres 8192 mas 28 22:36 /var/lib/postgresql/13/main/base/16527/16528
Существует полезное расширение oid2name, входящее в стандартную поставку, с помощью которого можно легко
связать объекты БД и файлы.
Можно посмотреть все базы данных:
student$ /usr/lib/postgresql/13/bin/oid2name
All databases:
 Oid Database Name Tablespace
 16527 data_lowlevel pg_default
 13485
        postgres pg_default
            student pg_default
template0 pg_default
 16385
 13484
     1
            template1 pg_default
Можно посмотреть все объекты в базе:
student$ /usr/lib/postgresql/13/bin/oid2name -d data lowlevel
From database "data lowlevel":
 Filenode Table Name
    16530
Или все табличные пространства в базе:
student$ /usr/lib/postgresql/13/bin/oid2name -d data_lowlevel -s
All tablespaces:
  Oid Tablespace Name
 1663
       pg default
            pg_global
 1664
Можно по имени таблицы узнать имя файла:
student$ /usr/lib/postgresql/13/bin/oid2name -d data_lowlevel -t t
From database "data_lowlevel":
 Filenode Table Name
-----
    16530
Или наоборот, по номеру файла узнать таблицу:
student$ /usr/lib/postgresql/13/bin/oid2name -d data_lowlevel -f 16530
From database "data lowlevel":
 Filenode Table Name
```

16530 t

Размер слоев

Размер файлов, входящих в слой, можно, конечно, посмотреть в файловой системе, но существует специальная функция для получения размера каждого слоя в отдельности:

TOAST



Версия строки должна помещаться на одну страницу

можно сжать часть полей можно вынести часть полей в отдельную toast-таблицу можно сжать и вынести одновременно

Toast-таблица

находится в схеме pg_toast (pg_toast_temp_N) поддержана собственным индексом содержит фрагменты «длинных» значений размером меньше страницы читается только при обращении к «длинному» полю имеет собственную версионность используется прозрачно для приложения

6

Любая версия строки в PostgreSQL должна целиком помещаться на одну страницу. Для «длинных» версий строк применяется технология TOAST — The Oversized Attributes Storage Technique. Она подразумевает несколько стратегий работы с «длинными» полями. Значение поля может быть сжато так, чтобы версия строки поместилась на страницу. Значение может быть убрано из версии и перемещено в отдельную служебную таблицу. Могут применяться и оба подхода: какие-то значения будут сжаты, какие-то — перемещены, какие-то — сжаты и перемещены одновременно.

Для каждой основной таблицы при необходимости создается отдельная toast-таблица (и к ней специальный индекс). Такие таблицы и индексы располагаются в отдельной схеме pg_toast и поэтому обычно не видны (для временных таблиц используется схема pg_toast_temp_N аналогично обычной pg_temp_N).

Версии строк в toast-таблице тоже должны помещаться на одну страницу, поэтому длинные значения хранятся порезанными на фрагменты. Из этих фрагментов PostgreSQL прозрачно для приложения «склеивает» необходимое значение.

Тоаst-таблица используется только при обращении к длинному значению. Кроме того, для toast-таблицы поддерживается своя версионность: если обновление данных не затрагивает «длинное» значение, новая версия строки будет ссылаться на то же самое значение в toast-таблице — это экономит место.

https://postgrespro.ru/docs/postgresql/13/storage-toast

TOAST

```
В таблице t есть столбец типа numeric. Этот тип может работать с очень большими числами. Например, с такими:
```

Поскольку версия строки не может поместить на одну страницу, она хранится в отдельной toast-таблице. Тоast-таблица и индекс к ней создаются автоматически для каждой таблицы, в которой есть потенциально «длинный» тип данных, и используются по необходимости.

Имя и идентификатор такой таблицы можно найти следующим образом:

Вот и файлы toast-таблицы:

```
postgres$ ls -l /var/lib/postgresql/13/main/base/16527/16533*
```

```
-rw----- 1 postgres postgres 57344 мая 28 22:36 /var/lib/postgresql/13/main/base/16527/16533 -rw----- 1 postgres postgres 24576 мая 28 22:36 /var/lib/postgresql/13/main/base/16527/16533_fsm
```

Существуют несколько стратегий работы с длинными значениями. Название стратегии указывается в поле Storage:

```
=> \d+ t
```

```
Table "public.t"

Column | Type | Collation | Nullable | Default | Storage | Stats target | Description

id | integer | not null | generated always as identity | plain | n | numeric | | | | main | |

Indexes:

"t_pkey" PRIMARY KEY, btree (id)

Access method: heap
```

- plain TOAST не применяется (тип имеет фиксированную длину);
- extended применяется как сжатие, так и отдельное хранение;
- external сжатие не используется, только отдельное хранение;
- main обрабатываются в последнюю очередь с приоритетом сжатия.

данные, разумно поставить стратегию external.

Просто для примера:

=> ALTER TABLE t ALTER COLUMN n SET STORAGE external;

ALTER TABLE

Эта операция не меняет существующие данные в таблице, но определяет стратегию работы с новыми версиями строк.



Как уже говорилось, размер отдельного слоя можно получить функцией pg_relation_size. Чтобы не суммировать размеры отдельных слоев, есть несколько функций, показывающих размеры таблицы:

- pg_table_size показывает размер таблицы и ее toast-части (toast-таблицы и обслуживающего ее индекса), но без обычных индексов.
 Эту же функцию можно использовать для вычисления размера отдельного индекса: и таблицы, и индексы являются отношениями, и, несмотря на название, функция принимает любое отношение.
- pg_indexes_size суммирует размеры всех индексов таблицы, кроме индекса toast-таблицы.
- pg_total_relation_size показывает полный размер таблицы, вместе со всеми ее индексами.

Размер таблицы

Размер таблицы, включая toast-таблицу и обслуживающий ее индекс:

Для получения размера отдельного индекса можно воспользоваться функцией pg_table_size. Toast-части у индексов нет, поэтому функция покажет только размер всех слоев индекса (main, fsm).

Сейчас у таблицы только один индекс по первичному ключу, поэтому размер этого индекса совпадает со значением pg_indexes_size:

```
=> SELECT pg_table_size('t_pkey') AS t_pkey;
t_pkey
------
245760
(1 row)
```

Общий размер таблицы, включающий TOAST и все индексы:

Итоги



Объект представлен несколькими слоями Слой состоит из одного или нескольких файлов-сегментов Для «длинных» версий строк используется TOAST

10

Практика



- 1. Создайте нежурналируемую таблицу в пользовательском табличном пространстве и убедитесь, что для таблицы существует слой init.
 - Удалите созданное табличное пространство.
- 2. Создайте таблицу со столбцом типа text. Какая стратегия хранения применяется для этого столбца? Измените стратегию на external и вставьте в таблицу короткую и длинную строки.
 - Проверьте, попали ли строки в toast-таблицу, выполнив прямой запрос к ней. Объясните, почему.

11

1. Нежурналируемая таблица

```
student$ sudo mkdir /var/lib/postgresql/ts_dir
student$ sudo chown postgres /var/lib/postgresql/ts_dir
=> CREATE TABLESPACE ts LOCATION '/var/lib/postgresql/ts_dir';
CREATE TABLESPACE
=> CREATE DATABASE data_lowlevel;
CREATE DATABASE
=> \c data_lowlevel
You are now connected to database "data_lowlevel" as user "student".
=> CREATE UNLOGGED TABLE u(n integer) TABLESPACE ts;
CREATE TABLE
=> INSERT INTO u(n) SELECT n FROM generate_series(1,1000) n;
INSERT 0 1000
=> SELECT pg_relation_filepath('u');
                        pg_relation_filepath
 pg_tblspc/16705/PG_13_202007201/16706/16707
(1 row)
Посмотрим на файлы таблицы.
Обратите внимание, что следующая команда ls выполняется от имени пользователя postgres. Чтобы повторить такую команду,
удобно сначала открыть еще одно окно терминала и переключиться в нем на другого пользователя командой:
student$ sudo su postgres
И затем в этом же окне выполнить:
postgres \$ \ ls \ -l \ /var/lib/postgresql/13/main/pg\_tblspc/16705/PG\_13\_202007201/16706/16707* + lib/postgresql/13/main/pg\_tblspc/16705/PG\_13\_202007201/16706/16707* + lib/postgresql/13/main/pg\_tblspc/16705/PG\_13\_202007201/16706/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/pg\_tblspc/16705/PG\_13/main/ps_tblspc/16705/main/ps_tblspc/16705/PG\_13/main/ps_tblspc/16705/PG\_13/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/main/ps_tblspc/16705/mai
-rw----- 1 postgres postgres 40960 мая 28 22:41 /var/lib/postgresql/13/main/pg tblspc/16705/PG 13 202007201/16706/16707
-rw----- 1 postgres postgres 24576 mag 28 22:41 /var/lib/postgresql/13/main/pg_tblspc/16705/PG_13_202007201/16706/16707_fsm
                                                                        0 мая 28 22:41 /var/lib/postgresql/13/main/pg_tblspc/16705/PG_13_202007201/16706/16707_init
-rw----- 1 postgres postgres
Удалим созданное табличное пространство:
=> DROP TABLE u;
DROP TABLE
=> DROP TABLESPACE ts;
DROP TABLESPACE
2. Таблица с текстовым столбцом
=> CREATE TABLE t(s text);
CREATE TABLE
=> \d+ t
                                                                          Table "public.t"
  {\tt Column~|~Type~|~Collation~|~Nullable~|~Default~|~Storage~|~Stats~target~|~Description} \\
-------
 S
                | text |
                                                    | extended |
Access method: heap
По умолчанию для типа text используется стратегия extended.
```

Изменим стратегию на external:

Проверим toast-таблицу:

```
=> ALTER TABLE t ALTER COLUMN s SET STORAGE external;
ALTER TABLE
=> INSERT INTO t(s) VALUES ('Κοροτκαя строка.');
INSERT 0 1
=> INSERT INTO t(s) VALUES (repeat('A',3456));
INSERT 0 1
```

Toast-таблица «спрятана», так как находится в схеме, которой нет в пути поиска. И это правильно, поскольку TOAST работает прозрачно для пользователя. Но заглянуть в таблицу все-таки можно:

Видно, что в TOAST-таблицу попала только длинная строка (два фрагмента, общий размер совпадает с длиной строки). Короткая строка не вынесена в TOAST просто потому, что в этом нет необходимости — версия строки и без этого помещается в страницу.

Практика+



1. Создайте базу данных.

Сравните размер базы данных, возвращаемый функцией pg_database_size, с общим размеров всех таблиц в этой базе. Объясните полученный результат.

12

1. Список таблиц базы данных можно получить из таблицы pg_class системного каталога.

1. Сравнение размеров базы данных и таблиц в ней

```
=> CREATE DATABASE data_lowlevel;
CREATE DATABASE
=> \c data_lowlevel
You are now connected to database "data_lowlevel" as user "student".
```

Даже пустая база данных содержит таблицы, относящиеся к системного каталогу. Полный список отношений можно получить из таблицы pg_class. Из выборки надо исключить:

- таблицы, общие для всего кластера (они не относятся к текущей базе данных);
- индексы и toast-таблицы (они будут автоматически учтены при подсчета размера).

```
=> SELECT sum(pg_total_relation_size(oid))
FROM pg_class
WHERE NOT relisshared -- локальные объекты базы
AND relkind = 'r'; -- обычные таблицы

sum
7979008
(1 row)
```

Размер базы данных оказывается несколько больше:

Дело в том, что функция pg_database_size возвращает размер каталога файловой системы, а в этом каталоге находятся несколько служебных файлов.

```
=> SELECT oid FROM pg_database WHERE datname = 'data_lowlevel';
  oid
-----
16717
(1 row)
```

Обратите внимание, что следующая команда ls выполняется от имени пользователя postgres. Чтобы повторить такую команду, удобно сначала открыть еще одно окно терминала и переключиться в нем на другого пользователя командой:

```
student$ sudo su postgres
```

И затем в этом же окне выполнить:

```
postgres$ ls -l /var/lib/postgresql/13/main/base/16717/[^0-9]*
```

```
-rw----- 1 postgres postgres 512 mag 28 22:41 /var/lib/postgresql/13/main/base/16717/pg_filenode.map -rw----- 1 postgres postgres 151596 mag 28 22:41 /var/lib/postgresql/13/main/base/16717/pg_internal.init -rw----- 1 postgres postgres 3 mag 28 22:41 /var/lib/postgresql/13/main/base/16717/PG_VERSION
```

- pg filenode.map отображение oid некоторых таблиц в имена файлов;
- pg_internal.init кеш системного каталога;
- PG VERSION версия PostgreSQL.

Из-за того, что одни функции работают на уровне объектов базы данных, а другие — на уровне файловой системы, бывает сложно точно сопоставить возвращаемые размеры. Это относится и к функции pg tablespace size.